

# ALGORITHMEN UND DATENSTRUKTUREN

## ÜBUNG 13: EM-ALGORITHMUS

---

Eric Kunze

`eric.kunze@mailbox.tu-dresden.de`

TU Dresden, 05.02.2021

# EM-Algorithmus

---

Wir betrachten ein Zufallsexperiment mit

- ▶ Ergebnismenge  $X$  und
- ▶ einer Funktion  $p: X \rightarrow [0, 1]$  mit  $\sum_{x \in X} p(x) = 1$   
(**Wahrscheinlichkeitsverteilung von  $X$** )

Die Menge aller Wahrscheinlichkeitsverteilungen über  $X$  sei  $\mathcal{M}(X)$ . Jede Teilmenge  $\mathcal{M} \subseteq \mathcal{M}(X)$  heißt **Wahrscheinlichkeitsmodell**.

Führen wir nun zwei Zufallsexperimente nacheinander aus. Wir nehmen dabei an, dass die beiden Experimente *unabhängig* voneinander sind. Folge das erste Experiment einer Verteilung  $p_1 \in \mathcal{M}(X_1)$  und das zweite Experiment einer Verteilung  $p_2 \in \mathcal{M}(X_2)$ , dann ist  $p_1 \times p_2 \in \mathcal{M}(X_1 \times X_2)$  eine Verteilung auf der Ergebnismenge  $X_1 \times X_2$  unseres zweistufigen Experiments:

$$(p_1 \times p_2)(a, b) = p_1(a) \cdot p_2(b).$$

„Einzelwahrscheinlichkeiten multiplizieren / erste Pfadregel“

Oftmals wissen wir aber die zugrundeliegende Verteilung nicht, sondern können lediglich die Ergebnisse des Experiments wahrnehmen. Zählen wir diese Beobachtungen, dann nennen wir das einen **X-Korpus** modelliert durch eine Funktion  $h: X \rightarrow \mathbb{R}^{\geq 0}$ . Man definiert die **Korpuswahrscheinlichkeit / Likelihood** von  $h$  unter einer Verteilung  $p$  als

$$L(h, p) = \prod_{x \in X} p(x)^{h(x)}.$$

Nun kennen wir aber die Verteilung  $p$  nicht und müssen sie daher aus den beobachteten Daten schätzen. Dies macht der **Maximum-Likelihood-Schätzer** (MLE)

$$\text{mle}(h, \mathcal{M}) = \arg \max_{p \in \mathcal{M}} L(h, p).$$

Solange das Modell unbeschränkt gewählt wird, d.h. es werden alle Verteilungen über  $X$  zugelassen, dann wird der MLE zur relativen Häufigkeit von  $h$ .

# MARGINALISIERUNG

Wir betrachten die zwei Ergebnismengen  $X_1$  und  $X_2$ . Das Modell sei gegeben durch das unabhängige Produkt der Modelle auf  $X_1$  und der Modelle auf  $X_2$ , d.h.  $\mathcal{M} = \{p_1 \times p_2 : p_1 \in \mathcal{M}(X_1), p_2 \in \mathcal{M}(X_2)\}$ . Weiter sei  $h$  ein  $X_1 \times X_2$ -Korpus. Die Teilkorpora  $h_1$  auf  $X_1$  und  $h_2$  auf  $X_2$  erhalten wir durch **Marginalisierung**

$$h_1(x_1) = \sum_{x_2 \in X_2} h(x_1, x_2) \quad \text{für alle } x_1 \in X_1$$

$$h_2(x_2) = \sum_{x_1 \in X_1} h(x_1, x_2) \quad \text{für alle } x_2 \in X_2$$

Die Summen entsprechen dabei gerade Zeilen- bzw. Spaltensummen, wenn man  $h$  in einer Tabelle notiert.

$X_1 \backslash X_2$	$\alpha$	...	$\omega$	
$a$	$h(a, \alpha)$	...	$h(a, \omega)$	$h_1(a)$
$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\vdots$
$z$	$h(z, \alpha)$	...	$h(z, \omega)$	$h_1(z)$
	$h_2(\alpha)$	...	$h_2(\omega)$	

Der MLE auf  $X_1 \times X_2$  ist außerdem gegeben durch die relativen Häufigkeiten auf den Teilkorpora, d.h.  $\text{mle}(h, \mathcal{M}) = \text{rfe}(h_1) \times \text{rfe}(h_2)$ .

# UNVOLLSTÄNDIGE DATEN

Bisher sind wir davon ausgegangen, dass die Daten stets vollständig waren, d.h. wir konnten jedes Ergebnis beobachten. In der Realität können aber oftmals nur Gruppen von Ergebnissen beobachtet werden; z.B. Gewinne oder Verliere ich bei einem Spiel. Wir wissen aber nicht, welches Ergebnis genau erzielt wurde.

Sei  $Y$  die Menge der Beobachtungen. Die Beobachtungsfunktion  $\text{yield}: X \rightarrow Y$  ordnet jedem Ergebnis seine Beobachtung zu. Die Umkehrabbildung ordnet dann jeder Beobachtung eine Menge von möglichen Ergebnissen zu, die zu dieser Beobachtung führen, d.h.

$$A: Y \rightarrow \mathcal{P}(X) \quad \text{mit} \quad A(y) = \{x \in X : \text{yield}(x) = y\}.$$

Diese Funktion heißt **Analysator**.

Sei  $h$  ein  $Y$ -Korpus, d.h.  $h$  zählt Beobachtungen (nicht Ergebnisse). Die **Korpuswahrscheinlichkeit / Likelihood** von  $h$  unter einer Verteilung  $p$  ist

$$L(h, p) = \prod_{y \in Y} \left( \sum_{x \in A(y)} p(x) \right)^{h(y)}.$$

Der MLE bleibt wie er war:  $\text{mle}(h, \mathcal{M}) = \arg \max_{p \in \mathcal{M}} L(h, p).$

## **E-Schritt** *Expectation*

Bestimme die versteckten Eigenschaften mithilfe der Parameter aus der vorherigen Iteration.

$$h_i(x) = h(\text{yield}(x)) \cdot \frac{p_{i-1}(x)}{\sum_{x' \in A(\text{yield}(x))} p_{i-1}(x')}$$

## **M-Schritt** *Maximization*

Bestimme die neuen Parameter mithilfe des vollständigen Eigenschaften aus dem E-Schritt.

$$p_i = \arg \max_{p \in \mathcal{M}} L(h_i, p)$$

# Übungsblatt 13

## *Aufgabe 1*

---



## AUFGABE 1 — TEIL (A)

Das Spiel wird gewonnen, wenn beide Münzen auf der gleichen Seite landen.

Damit ist der Analysator  $A: \{\text{Gewinn}, \text{keinGewinn}\} \rightarrow \mathcal{P}(X)$  gegeben durch

$$\begin{aligned} A(\text{Gewinn}) &= \{x \in X : \text{yield}(x) = \text{Gewinn}\} \\ &= \{(K, K), (Z, Z)\} \end{aligned}$$

$$\begin{aligned} A(\text{keinGewinn}) &= \{x \in X : \text{yield}(x) = \text{keinGewinn}\} \\ &= \{(K, Z), (Z, K), (R, K), (R, Z)\} \end{aligned}$$

## AUFGABE 1 — TEIL (B)

Wir können nur die Beobachtungen Gewinn und keinGewinn feststellen.

Wir spielen das Spiel 24 Mal und gewinnen 6 Mal. Gesucht ist nun der  $Y$ -Korpus  $h$ , d.h. wie oft beobachten wir die Ereignisse Gewinn und keinGewinn.

$$h(\text{Gewinn}) = 6$$

$$h(\text{keinGewinn}) = 18$$

## AUFGABE 1 — TEIL (C)

Gegeben ist nun eine initiale Wahrscheinlichkeitsverteilung  $q_0 = q_0^1 \times q_0^2$  über den vollständigen Daten mit

$$q_0^1(K) = \frac{2}{5}$$

$$q_0^2(K) = \frac{1}{3}$$

$$q_0^1(R) = \frac{1}{5}$$

$$\Rightarrow q_0^1(Z) = 1 - q_0^1(K) - q_0^1(R) = \frac{2}{5}$$

$$q_0^2(Z) = 1 - q_0^2(K) = \frac{2}{3}$$

Mit dem unabhängigen Produkt erhalten wir

$$q_0(K, K) = q_0^1(K) \cdot q_0^2(K) = \frac{2}{15}$$

$$q_0(K, Z) = q_0^1(K) \cdot q_0^2(Z) = \frac{4}{15}$$

$$q_0(Z, K) = q_0^1(Z) \cdot q_0^2(K) = \frac{2}{15}$$

$$q_0(Z, Z) = q_0^1(Z) \cdot q_0^2(Z) = \frac{4}{15}$$

$$q_0(R, K) = q_0^1(R) \cdot q_0^2(K) = \frac{1}{15}$$

$$q_0(R, Z) = q_0^1(R) \cdot q_0^2(Z) = \frac{2}{15}$$

## AUFGABE 1 — TEIL (C)

**E-Schritt:** Erweiterung von  $h$  auf  $h_1$  mit folgender Formel:

$$h_1(x) = h(\text{yield}(x)) \cdot \frac{q_0(x)}{\sum_{x' \in A(\text{yield}(x))} q_0(x')}$$

Damit ergibt sich dann zum Beispiel für das Ergebnis  $(K, K)$

$$\begin{aligned} h_1(K, K) &= h(\text{Gewinn}) \cdot \frac{q_0(K, K)}{\sum_{x' \in \{(K, K), (Z, Z)\}} q_0(x')} \\ &= h(\text{Gewinn}) \cdot \frac{q_0(K, K)}{q_0(K, K) + q_0(Z, Z)} \\ &= 6 \cdot \frac{\frac{2}{15}}{\frac{2}{15} + \frac{4}{15}} \\ &= 2 \end{aligned}$$

Mit gleicher Rechnung erhalten wir für die restlichen Ereignisse

$$\begin{array}{lll} h_1(Z, K) = 4 & & h_1(R, K) = 2 \\ h_1(K, Z) = 8 & h_1(Z, Z) = 4 & h_1(R, Z) = 4 \end{array}$$

# AUFGABE 1 — TEIL (D)

**M-Schritt:** Bestimmung der Teilkorpora  $h_1^1$  bzw.  $h_1^2$  durch *Marginalisierung*:

$X_1 \backslash X_2$	$K$	$Z$	
$K$	$h_1(K, K)$	$h_1(K, Z)$	$h_1^1(K)$
$Z$	$h_1(Z, K)$	$h_1(Z, Z)$	$h_1^1(Z)$
$R$	$h_1(R, K)$	$h_1(R, Z)$	$h_1^1(R)$
	$h_1^2(K)$	$h_1^2(Z)$	

$\leadsto$

$X_1 \backslash X_2$	$K$	$Z$	
$K$	2	8	10
$Z$	4	4	8
$R$	2	4	6
	8	16	24

## AUFGABE 1 — TEIL (E)

Nun bestimmen wir noch die relativen Häufigkeiten mit der Formel

$$\text{rfe}(h)(x) := \frac{h(x)}{|h|} \quad \text{mit} \quad |h| := \sum_{x \in X} h(x)$$

Wenden wir dies nun auf  $h_1$  und  $h_2$  an, so erhalten wir

$$q_1^1(K) = \text{rfe}(h_1^1)(K) = \frac{h_1^1(K)}{h_1^1(K) + h_1^1(Z) + h_1^1(R)} = \frac{10}{24} = \frac{5}{12}$$

$$q_1^1(Z) = \text{rfe}(h_1^1)(Z) = \frac{h_1^1(Z)}{h_1^1(K) + h_1^1(Z) + h_1^1(R)} = \frac{8}{24} = \frac{1}{3}$$

$$q_1^1(R) = \text{rfe}(h_1^1)(R) = \frac{h_1^1(R)}{h_1^1(K) + h_1^1(Z) + h_1^1(R)} = \frac{6}{24} = \frac{1}{4}$$

und

$$q_1^2(K) = \text{rfe}(h_1^2)(K) = \frac{h_1^2(K)}{h_1^2(K) + h_1^2(Z)} = \frac{8}{24} = \frac{1}{3}$$

$$q_1^2(Z) = \text{rfe}(h_1^2)(Z) = \frac{h_1^2(Z)}{h_1^2(K) + h_1^2(Z)} = \frac{16}{24} = \frac{2}{3}$$